
 TD 1 : Eléments de correction

Exercice 1

1. On suppose que les $(x_i, y_i), i = 1, \dots, n$ sont des réalisations de variables aléatoires i.i.d. $(X_i, Y_i), i = 1, \dots, n$. On s'intéresse alors à la loi conditionnelle de Y sachant X .
2. Une règle de prévision est une fonction $g : \mathcal{X} \rightarrow \mathcal{Y}$.
3. La règle de Bayes est définie par

$$g^*(x) = \begin{cases} 1 & \text{si } \mathbf{P}(Y = 1|X = x) \geq 0.5 \\ 0 & \text{sinon.} \end{cases}$$

L'erreur de Bayes est définie par $L^* = \mathbf{P}(g^*(X) \neq Y)$.

4. On a

$$\begin{aligned} \mathbf{P}(g(X) \neq Y|X = x) &= 1 - (\mathbf{P}(g(X) = Y, g(X) = 1|X = x) + \mathbf{P}(g(X) = Y, g(X) = -1|X = x)) \\ &= 1 - (\mathbf{1}_{g(x)=1}\mathbf{P}(Y = 1|X = x) + \mathbf{1}_{g(x)=-1}\mathbf{P}(Y = -1|X = x)) \\ &= 1 - (\mathbf{1}_{g(x)=1}\eta(x) + \mathbf{1}_{g(x)=-1}(1 - \eta(x))). \end{aligned}$$

5. On déduit

$$\begin{aligned} \mathbf{P}(g(X) \neq Y|X = x) - \mathbf{P}(g^*(X) \neq Y|X = x) &= \eta(x) (\mathbf{1}_{g^*(x)=1} - \mathbf{1}_{g(x)=1}) + (1 - \eta(x)) (\mathbf{1}_{g^*(x)=-1} - \mathbf{1}_{g(x)=-1}) \\ &= (2\eta(x) - 1) (\mathbf{1}_{g^*(x)=1} - \mathbf{1}_{g(x)=1}) \\ &\geq 0 \end{aligned}$$

par définition de g^* .

6. En intégrant par rapport à μdx , où μ désigne la loi de X on obtient

$$\mathbf{P}(g(X) \neq Y) \geq \mathbf{P}(g^*(X) \neq Y)$$

pour toute règle g .

7. Si $x \leq 0$, on a

$$\mathbf{P}(Y = 1|X = x) = \mathbf{P}(U \leq 2|X = x) = \mathbf{P}(U \leq 2) = \frac{1}{5}.$$

De même si $x > 0$,

$$\mathbf{P}(Y = 1|X = x) = \mathbf{P}(U > 1|X = x) = \mathbf{P}(U > 1) = \frac{9}{10}.$$

On a donc

$$g^*(x) = \begin{cases} 0 & \text{si } x \leq 0 \\ 1 & \text{si } x > 0. \end{cases}$$

L'erreur de Bayes vaut

$$L^* = \mathbf{P}(g^*(X) \neq Y | X \leq 0) \mathbf{P}(X \leq 0) + \mathbf{P}(g^*(X) \neq Y | X > 0) \mathbf{P}(X > 0).$$

Or

$$\mathbf{P}(g^*(X) \neq Y | X \leq 0) = \mathbf{P}(Y \neq -1 | X \leq 0) = \mathbf{P}(U \leq -2 | X \leq 0) = \frac{1}{5}$$

et

$$\mathbf{P}(g^*(X) \neq Y | X > 0) = \mathbf{P}(Y \neq 1 | X > 0) = \mathbf{P}(U < 1 | X > 0) = \frac{1}{10}.$$

On obtient

$$L^* = \frac{1}{5} \frac{1}{2} + \frac{1}{10} \frac{1}{2} = \frac{3}{20}.$$

Exercice 2

1.

2. On désigne par $\mathcal{I}_k, k = 0, 1$ les indices des observations dans le groupe k . On a alors

$$L_{X|Y}(x_1, \dots, x_n) = \prod_{i \in \mathcal{I}_0} f_0(x_i) \prod_{i \in \mathcal{I}_1} f_1(x_i).$$

On obtient ainsi

$$\mathcal{L}_{X|Y}(x_1, \dots, x_n) = -(n_0 + n_1) \log(\sqrt{2\pi}) - (n_0 + n_1) \log \sqrt{\sigma^2} - \frac{1}{2} \sum_{i \in \mathcal{I}_0} \frac{(x_i - \mu_0)^2}{\sigma^2} - \frac{1}{2} \sum_{i \in \mathcal{I}_1} \frac{(x_i - \mu_1)^2}{\sigma^2}.$$

En dérivant par rapport à μ_0 et μ_1 il est facile de voir que les EMV de ces paramètres sont donnés par

$$\hat{\mu}_0 = \frac{1}{n_0} \sum_{i \in \mathcal{I}_0} x_i \quad \text{et} \quad \hat{\mu}_1 = \frac{1}{n_1} \sum_{i \in \mathcal{I}_1} x_i.$$

On dérive maintenant par rapport à σ^2 :

$$\frac{\partial \mathcal{L}_{X|Y}(x_1, \dots, x_n)}{\partial \sigma^2} = -\frac{n_0 + n_1}{\sigma^2} + \sum_{i \in \mathcal{I}_0} \frac{(x_i - \mu_0)^2}{2\sigma^4} + \sum_{i \in \mathcal{I}_1} \frac{(x_i - \mu_1)^2}{2\sigma^4}.$$

On déduit que l'EMV de σ^2 est donné par

$$\hat{\sigma}^2 = \frac{1}{n} \left(\sum_{i \in \mathcal{I}_0} (x_i - \hat{\mu}_0)^2 + \sum_{i \in \mathcal{I}_1} (x_i - \hat{\mu}_1)^2 \right).$$

3. Ces estimateurs correspondent à ceux proposés dans le cours, à part pour $\hat{\sigma}^2$ où on divise par $n - 2$ au lieu de n pour débiaiser.

Exercice 3

1.

2. Sous le modèle LDA, maximiser $\mathbf{P}(Y = k | X = x)$ est équivalent à maximiser $\pi_k f_k(x)$ où $f_k(x)$ est la densité d'un vecteur gaussien $\mathcal{N}(\mu_k, \Sigma)$. Par conséquent cela revient à maximiser

$$-\frac{1}{2}(x - \mu_k)^t \Sigma^{-1}(x - \mu_k) + \log(\pi_k),$$

ou encore

$$x^t \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^t \Sigma^{-1} \mu_k + \log \pi_k.$$

Exercice 4

1. On a

$$V = \frac{1}{n} \sum_{i=1}^n (X_i - g)(X_i - g)^t, \quad B = \frac{1}{n} \sum_{k=1}^K n_k (g_k - g)(g_k - g)^t,$$

$$W = \frac{1}{n} \sum_{k=1}^K \sum_{i: Y_i=k} (X_i - g_k)(X_i - g_k)^t.$$

2. Il est facile de voir que $\pi_a(u) = \frac{\langle u, a \rangle}{\|a\|^2} a$.

3. On a ainsi

$$V(a) = \frac{1}{n} \sum_{i=1}^n \|\pi_a(X_i - g)\|^2 = \frac{1}{n} \sum_{i=1}^n a^t (X_i - g)^t (X_i - g) a = a^t V a.$$

De même $B(a) = a^t B a$ et $W(a) = a^t W a$.

4. On écrit le Lagrangien

$$L(a, \lambda) = B(a) + \lambda W(a) = a^t (B + \lambda W) a,$$

puis on le dérive par rapport à a :

$$\frac{\partial L(a, \lambda)}{\partial a} = 2(B + \lambda W)a.$$

Par conséquent la solution a^* vérifie $W^{-1} B a^* = \lambda a^*$, c'est donc un vecteur propre de $W^{-1} B$. De plus, il est facile de voir que $J(a^*) = \lambda$, par conséquent a^* est un vecteur propre associé à la plus grande valeur propre de $W^{-1} B$.

5. $W^{-1} B$ possédant au plus une valeur propre non nulle, il suffit de vérifier que $W^{-1}(g_1 - g_0)$ est vecteur propre de $W^{-1} B$. On a

$$W^{-1} B W^{-1}(g_1 - g_0) = \frac{n_0 n_1}{n^2} W^{-1}(g_1 - g_0)(g_1 - g_0)^t W^{-1}(g_1 - g_0) = \lambda W^{-1}(g_1 - g_0)$$

avec

$$\lambda = \frac{n_0 n_1}{n^2} (g_1 - g_0)^t W^{-1}(g_1 - g_0).$$

6. Le nouvel x est affecté au groupe 1 si $\|\pi_{a^*}(x - g_1)\| \leq \|\pi_{a^*}(x - g_0)\|$. Or

$$\pi_{a^*}(x - g_1) = \frac{(x - g_1)^t a_1^*}{\|a_1^*\|^2} a_1^* \quad \text{et} \quad \pi_{a^*}(x - g_0) = \frac{(x - g_0)^t a_1^*}{\|a_1^*\|^2} a_1^*$$

où $a_1^* = W^{-1}(g_1 - g_0)$. Par conséquent, x est affecté au groupe 1 si

$$((x - g_1)^t a_1^*)^2 \leq ((x - g_0)^t a_1^*)^2 \iff -2x^t a_1^* \times g_1^t a_1^* + (g_1^t a_1^*)^2 \leq -2x^t a_1^* \times g_0^t a_1^* + (g_0^t a_1^*)^2$$

ou encore

$$2x^t a_1^* (g_0^t a_1^* - g_1^t a_1^*) \leq (g_0^t a_1^*)^2 - (g_1^t a_1^*)^2 = (g_0^t a_1^* + g_1^t a_1^*)(g_0^t a_1^* - g_1^t a_1^*).$$

Comme $g_0^t a_1^* - g_1^t a_1^* = -(g_1 - g_0)^t W^{-1}(g_1 - g_0) \leq 0$ on déduit que x est affecté au groupe 1 si

$$2x^t a_1^* \geq g_0^t a_1^* + g_1^t a_1^* \iff x^t W^{-1}(g_1 - g_0) \geq \frac{1}{2}(g_1 + g_0)^t W^{-1}(g_1 - g_0).$$

7. Il est facile de voir que $d(x, g_1) \leq d(x, g_0)$ si et seulement si

$$x^t W^{-1} g_1 - \frac{1}{2} g_1^t W^{-1} g_1 \leq x^t W^{-1} g_0 - \frac{1}{2} g_0^t W^{-1} g_0.$$

D'où le résultat.

8. Si on se place dans le modèle Gaussien d'analyse discriminante linéaire, x est affecté au groupe 1 si $\mathbf{P}(Y = 1|X = x) \geq \mathbf{P}(Y = 0|X = x)$, c'est-à-dire

$$\log(\pi_1) - \frac{1}{2}(x - \mu_1)^t \Sigma^{-1}(x - \mu_1) \geq \log(\pi_0) - \frac{1}{2}(x - \mu_0)^t \Sigma^{-1}(x - \mu_0),$$

ou encore

$$x^t \Sigma^{-1}(\mu_1 - \mu_0) \geq \frac{1}{2}(\mu_1 + \mu_0)^t \Sigma^{-1}(\mu_1 - \mu_0) + \log \frac{\pi_0}{\pi_1}.$$

On conclut en remarquant que si

- μ_0 et μ_1 sont estimés par g_0 et g_1 (ce qui est le cas généralement) ;
- Σ est, à une constante multiplicative près, estimé par W (ce qui est le cas généralement) ;
- les probabilités a priori π_0 et π_1 sont égales,

les 2 règles coïncident.

Exercice 5

On désigne par G^* le centre de gravité du nuage de points. Vu que les effectifs sont égaux, ce centre de gravité est donné par la moyenne des centres des groupes 0 et 1. On note $a^* = \text{vect}(\alpha_1, \alpha_2)$ le premier axe discriminant. Par définition, la frontière de l'analyse discriminante linéaire est donnée par l'ensemble des points M de coordonnées (x, y) tels que

$$\langle \overrightarrow{G^*M}, a^* \rangle = 0 \iff y = -\frac{\alpha_1}{\alpha_2}x + \frac{\alpha_1}{\alpha_2}G_x^* + G_y^*.$$

L'application numérique donne $y = 1.35x - 0.86$.




Figure 1: Frontière LDA.